

题目三 本地大模型部署及知识库问答

【实验目的】

1. 学习使用 Ollama 工具在 Linux 系统中部署大语言模型的完整过程
2. 实践通过 Ollama 部署 deepseek、通义千问模型并进行问答
3. 使用大语言模型对本地文档知识库进行问答

【实验环境】

计算机硬件要求（推荐）：16GB 内存、4 核 CPU、SSD 存储

实验软件：

1. 虚拟机软件：VirtualBox、VMware Workstation
2. Linux 操作系统：openEuler 或 Ubuntu
3. Ollama 0.6.8

【实验内容】

步骤一：创建虚拟机

1. 如果能在自己的计算机上直接安装 Linux 系统，则可以跳过本步骤，并且效果更佳。
2. 虚拟机设置，内存 > 8GB ， 硬盘容量 > 50GB 。
3. 网络连接方式选择“桥接网卡”，如图 1 所示。






图 1 网络连接方式

步骤二：虚拟机上安装 Linux 系统


1. 启动虚拟机软件，安装 Linux 操作系统。
2. 按照提示安装系统，安装过程中需要注意以下要点（以 openEuler 为例）：
 - 1) 软件选择页面：左侧选择 server，同时右侧勾选所需要的附加软件。




- 2) 网络和主机名页面：打开右侧的网络“开关”选项。



- 3) 安装目的地页面：选择出现的磁盘，接着点击 **Done** 。



4) 用户设置页面：启用 **root** 账号，并设置密码。



3. 使用 **root** 账号和密码登录 openEuler 虚拟机，查看并测试网络。

- 1) 运行命令 `hostnamectl set-hostname 学号`，将 Linux 主机名设置为你的学号。
- 2) 在命令行输入 `ping -c 3 www.baidu.com`，检查与外部网络的连通性。
- 3) 如果网络不通，修改计算机与虚拟机的网络设置，确保虚拟机与外网连通。

项目执行结果 1 上传：

在虚拟机命令行中执行 `hostnamectl ; ping -c 3 www.baidu.com` ,然后截图粘贴到项目报告指定位置。

步骤三：本地安装 ollama

方法一：网络安装

1. 下载 ollama，在命令行输入 `curl -fsSL https://ollama.com/install.sh | sh`（视国内外网络情况，可能多次安装不成功）。
2. 命令行输入 `ollama`，出现如下提示则表示安装成功。

```
[root@bogon ~]# ollama
Usage:
  ollama [flags]
  ollama [command]

Available Commands:
  serve      Start ollama
  create     Create a model from a Modelfile
  show       Show information for a model
  run        Run a model
  stop       Stop a running model
  pull       Pull a model from a registry
  push       Push a model to a registry
  list       List models
  ps         List running models
  cp         Copy a model
  rm         Remove a model
  help       Help about any command

Flags:
  -h, --help      help for ollama
  -v, --version    Show version information

Use "ollama [command] --help" for more information about a command.
```

方法二：软件包安装

1. 将教学群中发布的 `ollama-linux-amd64.tgz` 文件使用 `scp` 命令复制到虚拟机中 `root` 用户的家目录中，然后执行：

解压 Ollama 的 Linux 安装包到 `/usr` 目录下

`tar -C /usr -xzf ollama-linux-amd64.tgz`

```
[root@cernet2 llmrc]# tar -C /usr -xzf ollama-linux-amd64.tgz
[root@cernet2 llmrc]# ls /usr
bin  games  include  lib  lib64  libexec  local  sbin  share  src  tmp
[root@cernet2 llmrc]# find /usr -name ollama
/usr/bin/ollama
/usr/lib/ollama
```

2. 启动 ollama

启动 ollama（ollama 启动后会封锁当前终端）

`ollama serve`

3. 验证 ollama 是否成功执行

打开一个新终端，查看 ollama 是否已执行

`ollama -v`

说明：2）和 3）是为了验证是否成功安装了 ollama；验证安装成功后，结束 ollama 进程的执行。

4. 将 ollama 设置为自启动服务，依次执行如下命令
创建一个名为 ollama 的系统用户，设置其家目录为 /usr/share/ollama，并禁止登录 shell。

```
useradd -r -s /bin/false -U -m -d /usr/share/ollama ollama
```

将当前用户加入 ollama 用户组

```
usermod -a -G ollama $(whoami)
```

创建 Ollama 的 systemd 服务配置文件

```
cat << END > /etc/systemd/system/ollama.service
```

```
[Unit]
```

```
Description=Ollama Service
```

```
After=network-online.target
```

```
[Service]
```

```
ExecStart=/usr/bin/ollama serve
```

```
User=ollama
```

```
Group=ollama
```

```
Restart=always
```

```
RestartSec=3
```

```
Environment="PATH=$PATH"
```

```
[Install]
```

```
WantedBy=default.target
```

```
END
```

重新加载 systemd 配置文件

```
systemctl daemon-reload
```

设置 ollama 服务为开机自启

```
systemctl enable ollama
```

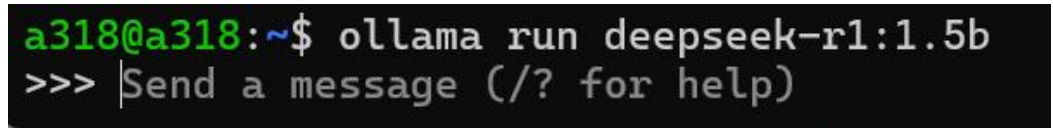
说明：参考 ollama 官网 <https://github.com/ollama/ollama/blob/main/docs/linux.md>

步骤四：运行大模型问答

1. 运行 DeepSeek 模型

命令行中输入以下命令运行 deepseek-r1:1.5b 模型：

```
ollama run deepseek-r1:1.5b
```



```
a318@a318:~$ ollama run deepseek-r1:1.5b
>>> | Send a message (/? for help)
```

2. 与大模型交互

- 输入问题和大模型进行交流；
- 退出大模型时，输入命令 `/bye`。

3. 运行通义千问 3 模型

命令行中输入以下命令运行 `qwen3:1.7b` 模型：

```
ollama run qwen3:1.7b
```

输入问题和大模型进行交流。

说明：若需其他模型，可访问 [Ollama 官网](<https://ollama.com/search>) 查看支持列表。

项目执行结果 2 上传：

分别向 DeepSeek 和通义千问大模型提问“openEuler 系统是什么”，结果截图粘贴到项目报告文件中指定位置。

步骤五：实现本地知识库问答

1. 安装依赖环境

(1) 检查 Python 版本与安装

- 在终端输入以下命令确认是否已安装 Python3 并查看其版本：
`python3 -V`
- 若返回类似 `Python 3.x.x` 的信息（如 `Python 3.11.4`），则说明已正确安装。
- 若未检测到 Python3，请执行以下命令进行安装：

```
dnf -y install python3
```

版本要求：确保版本 ≥ 3.11 （例如：3.11.x, 3.12+）。

(2) 创建 Python 虚拟环境（Virtual Environment），执行如下命令：

```
cd
mkdir ragllm
python3 -m venv myenv
source myenv/bin/activate
```

(3) 使用 pip 命令安装 Python 虚拟环境所需的包。

```
pip install llama_index
pip install llama-index transformers
pip install llama_index.llms.ollama
pip install langchain
pip install langchain_community
export HF_ENDPOINT=https://hf-mirror.com
pip install llama-index-embeddings-langchain
pip install docx2txt
pip install PyPDF2
pip install pdfplumber
```

```

pip install pymupdf
pip install llama-index llama-index-embeddings-huggingface
llama-index-llms-openai llama-index-readers-file
llama-index-vector-stores-kdbai

```

2. 上传文件

- 1) 将教学群中发布的 qaeuler.py 和 openEuler.txt 文件使用 scp 命令复制到虚拟机中 root 用户的家目录中。
- 2) 将 qaeuler.py 和 openEuler.txt 移动到 ragllm 目录。
- 3) 进入 ragllm 目录，创建子目录 data，将 openEuler.txt 移动到 data 目录中。

3. 本地知识库问答

- 1) 在已激活的 myenv 虚拟环境中运行命令（例如：通过执行 source myenv/bin/activate 激活环境）python3 qaeuler.py，等待查看执行结果。

2) 使用 vi 打开文件 qaeuler.py，按照图 2 所示信息，分别修改程序中模型名称、知识库目录与问题，实现不同问答效果。图 2 中第一处橙线位置用于设置模型名称；第二处橙线位置用于设置存放知识库文档的目录；第三处橙线位置用于设置问题。

```

from llama_index.core import VectorStoreIndex, SimpleDirectoryReader, Settings
from llama_index.llms.ollama import Ollama

# 配置ollama的LLM模型，这里我们用deepseek-r1:1.5b
Settings.llm = Ollama(model="deepseek-r1:1.5b", request_timeout=600.0)

# 配置HuggingFaceEmbeddings嵌入模型，这里我们用BAAI/bge-small-zh-v1.5
from langchain_community.embeddings import HuggingFaceEmbeddings
Settings.embed_model = HuggingFaceEmbeddings(model_name="BAAI/bge-small-zh-v1.5")

# 将data文件夹下的文档建立索引
documents = SimpleDirectoryReader("data").load_data()
index = VectorStoreIndex.from_documents(documents)

# 创建问答引擎，并提一个简单的问题
query_engine = index.as_query_engine()
response = query_engine.query("OpenEuler是什么? ")
print(response)

```

图 2 qaeuler.py

- 3) 修改 qaeuler.py 文件中的模型设置，通过通义千问 3（qwen3:1.7b）模型进行本地知识库问答（问题不变）。

4) 修改 qaeuler.py 文件中的问题，重新运行 qaeuler.py。（默认为“OpenEuler 是什么？”，可以修改为“OpenEuler 有什么基本指令？”等等与 OpenEuler 相关的问题）。

5) 设计实验验证本项目的本地知识库问答能力，如将不同专题的 linux 知识存储于多个 txt 文件中，查看问答效果（问答输出时间与准确度）；将文本知识分别存储于 docx 文件中、pdf 文件中，查看能否进行正常问答。

- 6) 完成实验后，命令行中输入 deactivate 退出 myenv 虚拟环境。

项目执行结果 3 上传：

将上面 1)、3)、4) 的执行结果截图粘贴到项目报告指定位置。